

Progetto BI - Area IT & BI - Il caso Titanic

Colombini Francesco

18/03/2026

Sommario

Introduzione	2
Caricamento del file	2
Pulizia dei dati	3
Perché il contesto conta	4
Analisi Esplorativa dei dati	5
1. Variabile target: survived	5
2. Distribuzione età	6
3. Distribuzione tariffa	7
4. Sopravvivenza per classe	8
5. Sopravvivenza per Genere	9
6. Genere $\times$ Classe	10
7. Porto d'imbarco	11
8. Sopravvivenza per parch	13
9. Settore cabina	15
10. Matrice di correlazione	16
11. Valori mancanti	18
Sviluppi futuri	19

Introduzione

Il naufragio del RMS Titanic, avvenuto nella notte tra il 14 e il 15 aprile 1912, rappresenta uno degli eventi più documentati e analizzati della storia moderna. La nave, considerata inaffondabile, colpì un iceberg nell'Oceano Atlantico settentrionale durante il suo viaggio inaugurale da Southampton a New York.

Caricamento del file

```
library(tidyverse)
titanic <- as_tibble(read_csv("Titanic_Dataset.csv"))
```

```
## Rows: 1309 Columns: 14
## -- Column specification -----
## Delimiter: ","
## chr (7): name, sex, ticket, cabin, embarked, boat, home.dest
## dbl (7): pclass, survived, age, sibsp, parch, fare, body
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
#View(titanic)
summary(titanic)
```

```
##      pclass      survived      name      sex
## Min.   :1.000   Min.   :0.000   Length:1309   Length:1309
## 1st Qu.:2.000   1st Qu.:0.000   Class :character   Class :character
## Median :3.000   Median :0.000   Mode  :character   Mode  :character
## Mean    :2.295   Mean    :0.382
## 3rd Qu.:3.000   3rd Qu.:1.000
## Max.    :3.000   Max.    :1.000
##
##      age      sibsp      parch      ticket
## Min.   : 0.17   Min.   :0.0000   Min.   :0.000   Length:1309
## 1st Qu.: 21.00   1st Qu.:0.0000   1st Qu.:0.000   Class :character
## Median : 28.00   Median :0.0000   Median :0.000   Mode  :character
## Mean    : 29.94   Mean    :0.4989   Mean    :0.385
## 3rd Qu.: 39.00   3rd Qu.:1.0000   3rd Qu.:0.000
## Max.    :120.00   Max.    :8.0000   Max.    :9.000
## NA's    :270
##      fare      cabin      embarked      boat
## Min.   : 0.000   Length:1309   Length:1309   Length:1309
## 1st Qu.: 7.896   Class :character   Class :character   Class :character
## Median : 14.454   Mode  :character   Mode  :character   Mode  :character
## Mean    : 40.904
## 3rd Qu.: 31.275
## Max.    :10000.000
## NA's    :11
##      body      home.dest
## Min.   : 1.0   Length:1309
## 1st Qu.: 72.0   Class :character
```

```
## Median :155.0   Mode  :character
## Mean    :160.8
## 3rd Qu.:256.0
## Max.    :328.0
## NA's    :1188
```

Pulizia dei dati

```
titanic$pclass <- as.factor(titanic$pclass)
titanic$survived <- as.logical(titanic$survived)
titanic$sex <- as.factor(titanic$sex)
titanic$boat <- as.factor(titanic$boat)
titanic$embarked <- as.factor(titanic$embarked)
titanic$boat <- as.factor(titanic$boat)
titanic$sibsp <- as.factor(titanic$sibsp)
titanic$parch <- as.factor(titanic$parch)
titanic$fare <- round(titanic$fare, 2)

titanic <- titanic %>%
  filter(sex != "unknown") %>% #remove 1 line of category "unknown"
  mutate(sex = droplevels(sex)) %>%
  filter(embarked != c("NA's", "X")) %>% #remove 3 lines of category "NA'S" or "X"
  mutate(embarked = droplevels(embarked)) %>%
  mutate(age = ifelse(age < 1, 1, floor(age))) %>%
  mutate(boat = ifelse(is.na(boat), "None", boat))

titoli <- c("Mr\\.", "Mrs\\.", "Miss\\.", "\\.", "\\.")

titanic$name <- str_replace_all(titanic$name, paste(titoli, collapse = "|"), "")
titanic$name <- str_replace_all(titanic$name, " ", " ")

# Creazione delle nuove colonne
titanic <- titanic %>%
  mutate(
    Buyer = str_trim(str_extract(name, "^([\\(\\+)]")),
    Passenger = ifelse(str_detect(name, "\\((\\.\\?)\\)"),
      str_extract(name, "\\((\\.\\?)\\)"),
      Buyer)
  ) %>%
  select(-name) %>%
  select(pclass, survived, Buyer, Passenger, everything())

titanic <- titanic %>%
  mutate(
    cabin_sector = substr(cabin, 1, 1), # Estrae la lettera del settore
    cabin_sector = ifelse(is.na(cabin), "None", cabin_sector),
    cabin_rooms = trimws(gsub("[A-Z]", "", cabin)),
    cabin_rooms = gsub("\\s+", "", cabin_rooms),
    cabin_rooms = ifelse(is.na(cabin_rooms), "None", cabin_rooms)
  ) %>%
  select(-cabin)
```

```
titanic$cabin_sector <- as.factor(titanic$cabin_sector)

summary(titanic)
```

```
## pclass    survived          Buyer          Passenger          sex
## 1:319    Mode :logical    Length:1305    Length:1305    female:463
## 2:277    FALSE:808        Class :character    Class :character    male :842
## 3:709    TRUE :497         Mode :character    Mode :character
##
##
##
##
##      age      sibsp      parch      ticket      fare
## Min.   : 1.00    0:888    0      :998    Length:1305    Min.   : 0.00
## 1st Qu.: 21.00    1:319    1      :170    Class :character    1st Qu.: 7.90
## Median : 28.00    2: 41    2      :113    Mode :character    Median : 14.45
## Mean   : 29.86    3: 20    3      : 8      Mean   : 40.87
## 3rd Qu.: 39.00    4: 22    4      : 6      3rd Qu.: 31.27
## Max.   :120.00    5: 6     5      : 6      Max.   :10000.00
## NA's   :270      8: 9     (Other): 4      NA's   :11
## embarked    boat          body          home.dest          cabin_sector
## C:270      Length:1305      Min.   : 1.0    Length:1305      None   :1014
## Q:123      Class :character    1st Qu.: 72.0    Class :character    C      : 93
## S:912      Mode :character    Median :155.0    Mode :character    B      : 63
##                                     Mean   :160.8      D      : 46
##                                     3rd Qu.:256.0      E      : 41
##                                     Max.   :328.0      A      : 21
##                                     NA's   :1184      (Other): 27
## cabin_rooms
## Length:1305
## Class :character
## Mode :character
##
##
##
##
```

Questo dataset raccoglie informazioni dettagliate su 1.305 passeggeri, includendo variabili demografiche, socio-economiche e logistiche. Prima di procedere con qualsiasi analisi, è però fondamentale **capire il contesto storico e fisico** in cui questi dati sono stati generati: un numero grezzo non racconta nulla se non sappiamo cosa rappresenta.

Perché il contesto conta

Prendiamo ad esempio la variabile `cabin_sector`: sapere che una cabina appartiene al settore “B” o “C” è irrilevante finché non si comprende **dove si trovavano fisicamente queste cabine sulla nave**. Le cabine di prima classe erano concentrate nei ponti superiori e centrali, quelle di terza classe nei ponti inferiori e a prua — una distinzione che, durante l'affondamento, si è tradotta letteralmente in una questione di vita o di morte: chi era più in basso aveva meno tempo e meno accesso alle scialuppe.


Allo stesso modo, variabili come `embarked` (porto di imbarco) o `fare` acquisiscono significato diverso se si sa che Cherbourg era il porto dove salirono a bordo prevalentemente passeggeri facoltosi di prima classe, mentre Queenstown era il punto di partenza di molti emigranti irlandesi diretti in America.

Per approfondire la disposizione delle cabine e la loro relazione con la sopravvivenza, si rimanda a : Class, Gender and the Titanic Disaster — Encyclopedia Titanica

Analisi Esplorativa dei dati

1. Variabile target: survived

```
titanic %>%  
  count(survived) %>%  
  mutate(pct = n / sum(n)) %>%  
  ggplot(aes(x = survived, y = n, fill = as.character(survived))) +  
  geom_col(width = 0.5, show.legend = FALSE) +  
  geom_text(aes(label = paste0(n, "\n(", percent(pct, 1), "%)")),  
            vjust = -0.3, size = 4.5) +  
  scale_fill_manual(values = pal_survived) +  
  scale_y_continuous(limits = c(0, max(count(titanic, survived)$n) * 1.2)) +  
  labs(title = "Distribuzione Sopravvissuti",  
       x = "Sopravvissuto", y = "Conteggio") +  
  tema
```



Il dataset è **sbilanciato**: solo il 38% dei passeggeri è sopravvissuto (497 su 1305). Questo squilibrio non è casuale, dato che riflette la realtà di una nave con scialuppe sufficienti per meno della metà dei passeggeri a


bordo. Dal punto di vista analitico, lo sbilanciamento è un avvertimento importante: un modello predittivo che classificasse *tutti* come non sopravvissuti raggiungerebbe già un'accuratezza del 62% senza imparare nulla. Metriche come **precision**, **recall** e **F1-score** saranno quindi preferibili alla semplice accuracy in fasi successive.

2. Distribuzione età

```
p_hist <- titanic %>% filter(!is.na(age)) %>%
  ggplot(aes(x = age, fill = as.character(survived))) +
  geom_histogram(binwidth = 5, alpha = 0.75, position = "identity") +
  scale_fill_manual(values = pal_survived, labels = c("Non sopravvissuto", "Sopravvissuto")) +
  scale_y_continuous(limits = c(0, 120)) +
  labs(title = "Istogramma Età", x = "Età", y = "Conteggio", fill = NULL) +
  tema

p_box <- titanic %>% filter(!is.na(age)) %>%
  ggplot(aes(x = as.character(survived), y = age,
    fill = as.character(survived))) +
  geom_boxplot(outlier.alpha = 0.4, show.legend = FALSE) +
  geom_text(stat = "summary", fun = median,
    aes(label = paste0("Md: ", round(after_stat(y), 0))),
    vjust = -0.5, size = 3.8) +
  scale_fill_manual(values = pal_survived) +
  scale_x_discrete(labels = c("Non sopravv.", "Sopravv.")) +
  labs(title = "Boxplot Età", x = NULL, y = "Età") +
  tema

p_hist | p_box
```



La distribuzione dell'età è sostanzialmente simile tra sopravvissuti e non, con mediana quasi identica (28 vs 27 anni). Tuttavia, guardando le code della distribuzione emergono due segnali interessanti: una **leggera sovrarappresentazione dei bambini (0–10 anni)** tra i sopravvissuti, coerente con il protocollo “prima le donne e i bambini”, e una **sottorappresentazione degli anziani over 60**, probabilmente meno reattivi


in una situazione di panico notturno in acque gelide. L'età da sola è un predittore debole, ma acquista forza se combinata con sesso e classe — un uomo anziano di terza classe aveva probabilità di sopravvivenza quasi nulla.

3. Distribuzione tariffa

```
p_hist_fare <- titanic %>% filter(!is.na(fare), fare > 0) %>%
  ggplot(aes(x = fare, fill = as.character(survived))) +
  geom_histogram(bins = 40, alpha = 0.75, position = "identity") +
  scale_x_log10(labels = dollar_format()) +
  scale_fill_manual(values = pal_survived, labels = c("Non sopravvissuto", "Sopravvissuto")) +
  labs(title = "Istogramma Tariffa (scala log)",
       x = "Tariffa (£)", y = "Conteggio", fill = NULL) +
  tema

p_box_fare <- titanic %>% filter(!is.na(fare)) %>%
  ggplot(aes(x = as.character(survived), y = fare,
            fill = as.character(survived))) +
  geom_boxplot(outlier.alpha = 0.3, show.legend = FALSE) +
  scale_y_log10(labels = dollar_format()) +
  geom_text(stat = "summary", fun = median,
            aes(label = paste0("Md: £", round(after_stat(y), 0))),
            vjust = -0.5, size = 3.8) +
  scale_fill_manual(values = pal_survived) +
  scale_x_discrete(labels = c("Non sopravv.", "Sopravv.")) +
  labs(title = "Boxplot Tariffa (scala log)", x = NULL, y = "Tariffa (£)") +
  tema

p_hist_fare | p_box_fare
```




I sopravvissuti hanno pagato tariffe significativamente più alte (mediana ~£26 vs ~£11 dei non sopravvissuti). La scala logaritmica è necessaria perché la distribuzione delle tariffe è fortemente asimmetrica a destra: la maggioranza pagava tra £7 e £30, ma alcuni passeggeri di prima classe superavano £500. Vale la pena notare

che la **tariffa non è una causa diretta della sopravvivenza** — è un *proxy* della classe del biglietto, che a sua volta determina la posizione della cabina sulla nave e la priorità di accesso alle scialuppe. Questo è un esempio classico di **variabile confondente**: fare e survived sono correlate, ma la relazione causale passa attraverso pclass. Per comprenderne meglio le relazioni sarebbe necessario realizzare una rete causale tra le variabili.

4. Sopravvivenza per classe

```
titanic %>%
  group_by(pclass) %>%
  summarise(
    n          = n(),
    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso       = mean(survived, na.rm = TRUE)
  ) %>%
  ggplot(aes(x = pclass, y = tasso, fill = pclass)) +
  geom_col(show.legend = FALSE, width = 0.6) +
  geom_text(aes(label = paste0(percent(tasso, 1), "\n(", sopravvissuti, "/", n, ")")),
    vjust = -0.3, size = 4.2) +
  scale_fill_manual(values = pal_pclass) +
  scale_y_continuous(labels = percent, limits = c(0, 0.85)) +
  labs(title = "Tasso di Sopravvivenza per Classe",
    x = "Classe", y = "Tasso di sopravvivenza") +
  tema
```





Il gradiente di sopravvivenza per classe è netto e impietoso: **62% in prima classe, 43% in seconda, solo 26% in terza**. Questi numeri non riflettono soltanto un privilegio sociale astratto, ma una geografia fisica precisa: le cabine di prima classe occupavano i ponti superiori centrali, a pochi passi dai punti di raccolta delle scialuppe. I passeggeri di terza classe, alloggiati nei ponti inferiori e a prua, dovevano percorrere corridoi lunghi, in alcuni casi trovandosi davanti cancelli chiusi a chiave, come documentato dalle testimonianze dell'epoca. La classe non era solo un comfort: era una distanza in metri dalle scialuppe.

5. Sopravvivenza per Genere

```
titanic %>%
  group_by(sex) %>%
  summarise(
    n = n(),
    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso = mean(survived, na.rm = TRUE)
  ) %>%
  ggplot(aes(x = sex, y = tasso, fill = sex)) +
  geom_col(show.legend = FALSE, width = 0.5) +
  geom_text(aes(label = paste0(percent(tasso, 1), "\n(n=", sopravvissuti, "/", n, ")")),
    vjust = -0.3, size = 4.2) +
  scale_fill_manual(values = pal_sex) +
  scale_y_continuous(labels = percent, limits = c(0, 0.9)) +
```

```
labs(title = "Tasso di Sopravvivenza per Genere",
     x = "Genere", y = "Tasso di sopravvivenza") +
tema
```




Il genere è il **predittore singolo più forte** dell'intero dataset: le donne sopravvivono al 73%, gli uomini solo al 19%. Il protocollo “prima le donne e i bambini”, è chiaramente visibile nei dati.

6. Genere × Classe

```
titanic %>%
  group_by(pclass, sex) %>%
  summarise(
    n = n(),
    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso = mean(survived, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot(aes(x = pclass, y = tasso, fill = sex)) +
  geom_col(position = "dodge", width = 0.7) +
  geom_text(aes(label = paste0(percent(tasso, 1), "\n(n=", sopravvissuti, "/", n, ")")),
            position = position_dodge(0.7), vjust = -0.3, size = 3.5) +
```

```
scale_fill_manual(values = pal_sex) +
scale_y_continuous(labels = percent, limits = c(0, 1.09)) +
labs(title = "Sopravvivenza per Classe e Sesso",
      x = "Classe", y = "Tasso di sopravvivenza", fill = "Sesso") +
tema
```



L'incrocio tra sesso e classe rivela la vera struttura della sopravvivenza. Le donne di prima e seconda classe raggiungono tassi straordinari (96% e 89%): erano praticamente al sicuro. Le donne di terza classe scendono al 49%, ancora meglio degli uomini di qualsiasi classe, ma lontane dalle loro compagne di viaggio più abbienti. Il dato più rivelatore è forse quello degli **uomini di prima classe (34%)**: pur avendo accesso privilegiato ai ponti superiori, sopravvivono a malapena a uno su tre. Il protocollo “donne prima” era evidentemente rispettato anche a scapito dei passeggeri più facoltosi. Questo suggerisce che **sesso e classe agiscono come predittori indipendenti**, con un'interazione significativa che nessun modello lineare semplice riuscirebbe a catturare.

7. Porto d'imbarco

```
p_embarked_tasso <- titanic %>%
  group_by(embarked) %>%
  summarise(
    n = n(),
```


```

    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso
      = mean(survived, na.rm = TRUE)
  ) %>%
  ggplot(aes(x = embarked, y = tasso, fill = embarked)) +
  geom_col(show.legend = FALSE, width = 0.6) +
  geom_text(aes(label = paste0(percent(tasso, 1), "\n(n=", sopravvissuti, "/", n, ")")),
    vjust = -0.3, size = 4.2) +
  scale_fill_manual(values = pal_embarked) +
  scale_y_continuous(labels = percent, limits = c(0, 0.65)) +
  labs(title = "Tasso di Sopravvivenza",
    x = "Porto", y = "Tasso di sopravvivenza") +
  tema

p_embarked_classe <- titanic %>%
  count(embarked, pclass) %>%
  group_by(embarked) %>%
  mutate(pct = n / sum(n)) %>%
  ungroup() %>%
  ggplot(aes(x = embarked, y = pct, fill = pclass)) +
  geom_col(width = 0.6) +
  geom_text(aes(label = ifelse(pct > 0.05, percent(pct, 1), "")),
    position = position_stack(vjust = 0.5), size = 3.8) +
  scale_fill_manual(values = pal_pclass) +
  scale_y_continuous(labels = percent) +
  labs(title = "Composizione per Classe",
    x = "Porto", y = "Proporzione", fill = "Classe") +
  tema

p_embarked_tasso | p_embarked_classe

```



Cherbourg registra il tasso di sopravvivenza più alto (56%), Southampton il più basso (33%). Questa differenza non ha nulla a che fare con la città di provenienza: è quasi interamente spiegabile dalla **composizione per classe** dei passeggeri imbarcati in ciascun porto. A Cherbourg salì una quota sproporzionata di passeggeri di prima classe, ricchi europei e americani in viaggio transatlantico. A Southampton si imbarcò la grande maggioranza dei passeggeri, con una distribuzione più pesata verso la terza classe. Queenstown, ultimo scalo prima dell'Atlantico aperto, era quasi esclusivamente un porto di emigrazione irlandese: famiglie intere che lasciavano l'Irlanda dirette in America, per lo più in terza classe. Il porto d'imbarco è quindi un **proxy sociologico** più che una variabile causale.

8. Sopravvivenza per parch

```
p_sibsp <- titanic %>%
  group_by(sibsp) %>%
  summarise(
    n = n(),
    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso = mean(survived, na.rm = TRUE)
  ) %>%
  ggplot(aes(x = sibsp, y = tasso, fill = tasso)) +
  geom_col(show.legend = FALSE, width = 0.7) +
  geom_text(aes(label = paste0(percent(tasso, 1))),
    vjust = -0.3, size = 3.8) +
  scale_fill_gradient(low = "#e05c5c", high = "#4caf82") +
  scale_y_continuous(labels = percent, limits = c(0, 0.75)) +
```


```

labs(title = "Sopravvivenza per \nN° Fratelli/Coniuge (sibsp)",
      x = "sibsp", y = "Tasso di sopravvivenza") +
tema

p_parch <- titanic %>%
  group_by(parch) %>%
  summarise(
    n = n(),
    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso = mean(survived, na.rm = TRUE)
  ) %>%
  ggplot(aes(x = parch, y = tasso, fill = tasso)) +
  geom_col(show.legend = FALSE, width = 0.7) +
  geom_text(aes(label = paste0(percent(tasso, 1))),
            vjust = -0.3, size = 3.8) +
  scale_fill_gradient(low = "#e05c5c", high = "#4caf82") +
  scale_y_continuous(labels = percent, limits = c(0, 0.75)) +
  labs(title = "Sopravvivenza per \nN° Genitori/Figli (parch)",
      x = "parch", y = "Tasso di sopravvivenza") +
tema

p_sibsp | p_parch

```



Le due variabili mostrano pattern strutturalmente simili ma con dinamiche distinte.

Per **sibsp** (fratelli/coniuge), il picco è a 1 (51%) e il tasso decresce progressivamente: avere un coniuge o

un fratello a bordo è un vantaggio concreto ci si sveglia, ci si orienta, ci si protegge a vicenda. Già con 2 fratelli/coniugi il tasso scende al 44%, riducendosi con l'incremento di quest ultimo. Questo andamento riflette quasi certamente la composizione sociale: chi aveva 4+ fratelli a bordo era tipicamente parte di famiglie numerose di emigranti in terza classe, dove la posizione della cabina e la mancanza di familiarità con la nave rendevano l'evacuazione quasi impossibile.


Per **parch** (genitori/figli), il pattern è meno lineare e più a **forma di campana asimmetrica**: si parte da 33% per chi viaggia senza figli né genitori, si sale fino al 62% per chi ne ha 3, per poi crollare bruscamente a 17% con 4-5 e 0% con 6 o 9. Il picco a **parch** = 3 è controintuitivo a prima vista — tre familiari sembrano tanti — ma probabilmente cattura un profilo specifico: una madre di prima o seconda classe con due o tre figli piccoli, che aveva sia la priorità di imbarco sia l'assistenza del personale di bordo. Al contrario, **parch** = 0 con solo 33% suggerisce che viaggiare senza legami familiari diretti significava spesso essere un uomo adulto solo, il profilo demografico con le minori probabilità di sopravvivenza dell'intero dataset.

9. Settore cabina

```
titanic %>%
  filter(!is.na(cabin_sector)) %>%
  group_by(cabin_sector) %>%
  summarise(
    n = n(),
    sopravvissuti = sum(survived, na.rm = TRUE),
    tasso = mean(survived, na.rm = TRUE)
  ) %>%
  ggplot(aes(x = cabin_sector, y = tasso, fill = cabin_sector)) +
  geom_col(show.legend = FALSE, width = 0.7) +
  geom_text(aes(label = paste0(percent(tasso, 1), "\nn=", n)),
    vjust = -0.3, size = 3.8) +
  scale_fill_manual(values = pal_cabin) +
  scale_y_continuous(labels = percent, limits = c(0, 0.85)) +
  labs(title = "Tasso di Sopravvivenza per Settore Cabina",
    subtitle = "Escluse cabine non registrate",
    x = "Settore", y = "Tasso di sopravvivenza") +
  tema
```

Tasso di Sopravvivenza per Settore Cabina

Escluse cabine non registrate



I settori B, D ed E mostrano i tassi più alti (70–73%), non per caso: corrispondono alle cabine di prima classe, quelle più vicini fisicamente alle scialuppe. Il settore A, curiosamente, ha il tasso più basso tra le cabine registrate (52%): si trovava a prua, più lontano dai punti di raccolta centrali. La categoria “None”, 1.014 passeggeri senza cabina registrata, mostra un tasso del 30%, vicino a quello della terza classe: non è un dato mancante casuale, ma una **mancanza strutturale**, perché la registrazione della cabina era pratica riservata alle classi superiori. Il dato assente è quindi esso stesso informativo.

10. Matrice di correlazione

```
cor_df <- titanic %>%
  mutate(
    survived_n = as.integer(survived),
    pclass_n   = as.integer(pclass),
    sibsp_n    = as.integer(sibsp),
    parch_n    = as.integer(parch),
    cabin_sector_n = as.integer(cabin_sector)
  ) %>%
  select(survived_n, pclass_n, age, fare, sibsp_n, parch_n, cabin_sector_n) %>%
  na.omit()


cor_df %>%
  cor() %>%
  as.data.frame() %>%
  rownames_to_column("var1") %>%
```



```

pivot_longer(-var1, names_to = "var2", values_to = "r") %>%
  ggplot(aes(x = var1, y = var2, fill = r)) +
  geom_tile(color = "white", linewidth = 0.5) +
  geom_text(aes(label = round(r, 2)), size = 3.8) +
  scale_fill_gradient2(low = "#e05c5c", mid = "white", high = "#4caf82",
    midpoint = 0, limits = c(-1, 1)) +
  labs(title = "Matrice di Correlazione", x = NULL, y = NULL, fill = "r") +
  theme_minimal(base_size = 12) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1),
    plot.title = element_text(face = "bold"))


```



Le correlazioni più forti con `survived_n` sono `pclass_n` (negativa, -0.31) e `fare` (positiva, $+0.08$ diretta, ma molto più forte tramite `pclass`). Il dato più rilevante per la modellazione futura è la **correlazione di 0.74 tra `cabin_sector_n` e `pclass_n`**: le due variabili misurano sostanzialmente la stessa cosa — la posizione socioeconomica del passeggero — e inserirle entrambe in un modello causerebbe **multicollinearità** severa. Sarà necessario scegliere l'una o l'altra, o costruire una variabile composita. La correlazione debole di `age` con tutto il resto conferma che l'età agisce principalmente attraverso interazioni con altre variabili, non come predittore lineare diretto.

11. Valori mancanti

```
titanic %>%
  summarise(across(everything(), ~mean(is.na(.)))) %>%
  pivot_longer(everything(), names_to = "var", values_to = "pct_na") %>%
  filter(pct_na > 0) %>%
  arrange(desc(pct_na)) %>%
  ggplot(aes(x = reorder(var, pct_na), y = pct_na, fill = pct_na)) +
  geom_col() +
  geom_text(aes(label = percent(pct_na, 1)), hjust = -0.15, size = 4) +
  scale_y_continuous(labels = percent, limits = c(0, 1.05)) +
  scale_fill_gradient(low = "#f0a500", high = "#c0392b") +
  coord_flip() +
  labs(title = "Percentuale Valori Mancanti per Variabile",
       x = NULL, y = "% NA") +
  theme_minimal(base_size = 13) +
  theme(legend.position = "none",
        plot.title = element_text(face = "bold"))
```



Il grafico dei valori mancanti racconta tre storie: - **body** (91% NA) è mancante per definizione: esiste solo per i non sopravvissuti i cui corpi furono recuperati dalla nave. La sua assenza non è un problema di qualità del dato, ma un fatto storico. - **home.dest** (43% NA) mancava già nei manifesti originali e riflette la disorganizzazione amministrativa di un imbarco massiccio. - **age** (21% NA) è invece il problema più rilevante per la modellazione: non è distribuito casualmente manca più spesso tra i passeggeri di terza classe e tra gli uomini, il che significa che una semplice imputazione con la media introdurrebbe bias sistematici.

Sviluppi futuri

Questa EDA ha messo in luce le strutture principali del dataset e identificato le variabili più rilevanti. I naturali passi successivi sono:

Feature engineering

Alcune variabili composite potrebbero migliorare significativamente un modello predittivo: un indicatore `is_alone` (1 se `sibsp=0` e `parch=0`), il titolo estratto dal nome originale (`Mr`, `Mrs`, `Miss`, `Master`, `Dr...`) come proxy dell'età e dello status sociale, o una variabile `deck` ricavata dal settore cabina con le informazioni storiche note sulla planimetria della nave.

Modellazione predittiva

Le variabili chiave emerse — `sex`, `pclass`, `age`, `fare` — sono i candidati per un modello di classificazione. Un punto di partenza solido è la **regressione logistica**, interpretabile e robusta, seguita da **Random Forest** per catturare le interazioni non lineari (sesso $\times$ classe in particolare). La metrica di riferimento non dovrà essere l'accuracy, ma l'**AUC-ROC** e l'**F1-score**, dati lo sbilanciamento della variabile target.

Analisi del testo su `home.dest`

La variabile `home.dest` contiene destinazioni come “New York, NY” o “Montreal, PQ”: una semplice categorizzazione geografica (Nord America, Europa, altro) potrebbe rivelare pattern migratori interessanti e aggiungere una dimensione sociologica all'analisi.

Analisi delle scialuppe (`boat`)

La variabile `boat` indica la scialuppa assegnata a ciascun sopravvissuto. Un'analisi per numero di scialuppa potrebbe rivelare quali ufficiali applicarono il protocollo “donne prima” più rigidamente e quali consentirono l'imbarco di uomini — aggiungendo una dimensione umana e narrativa all'analisi statistica.

Progetto svolto da Colombini Francesco utilizzando R Markdown e programmando di conseguenza in R
Link Github: [<https://github.com/FRA-0023>]